

UNIVERSIDAD DEL VALLE DE GUATEMALA  
Facultad de Ingeniería



**Análisis y Reconocimiento de Patrones de Señales Biomédicas  
de Pacientes con Epilepsia**

Protocolo de trabajo de graduación presentado por María Angulo,  
estudiante de Ingeniería Mecatrónica

Guatemala,

2020

## Resumen

El siguiente tema de investigación tiene como objetivo aplicar técnicas y algoritmos de aprendizaje de máquina a señales biomédicas de pacientes con epilepsia con el fin de encontrar características y patrones para detectar crisis epilépticas y analizar el comportamiento de las etapas previas a estas crisis. La metodología se empleará en cuatro fases principales: preprocesamiento de las señales, extracción de características, selección de características y diseño e implementación del clasificador utilizando máquinas de vectores de soporte y redes neuronales. Se evalúan los resultados mediante validación cruzada y matrices de confusión para presentar estadísticas del rendimiento de cada clasificador y se realizará un análisis de las ventajas y desventajas que se obtuvieron con cada uno.

Adicionalmente, los resultados alimentarán una base de datos con señales biomédicas de pacientes con epilepsia proporcionadas por el Centro de Epilepsia y Neurología Funcional Humana. Se trabajará en conjunto con la estudiante María Fernanda Pineda Esmieu, quien diseñará la estructura de la base de datos, para generar una herramienta de software mediante un entorno de desarrollo (Toolbox) en la plataforma MATLAB que permita facilitar la manipulación de las señales y presentación de resultados obtenidos en el presente trabajo.

## Antecedentes

La epilepsia es una enfermedad cerebral crónica. Se calcula que existen 50 millones de afectados por epilepsia en todo el mundo y se estima que entre un 4 % y un 5 % de la población mundial tendrá una crisis epiléptica en algún momento de su vida. Esto hace que la epilepsia sea tan común como la diabetes [1]. Debido a su presencia mundial, este trastorno es motivo de estudio en ámbitos de investigación biomédica, con el propósito de mejorar el proceso de diagnóstico, comprender sus posibles causas y brindar tratamientos efectivos para los pacientes.

El diagnóstico de este trastorno suele ser complejo. El electroencefalograma (EEG) es una prueba que comúnmente facilita el diagnóstico permitiendo registrar información de la actividad eléctrica del cerebro. Existe un campo amplio de investigación de esta herramienta diagnóstica, gracias a esto actualmente existe evidencia que afirma que en una crisis epiléptica se puede clasificar la actividad cerebral en cuatro estados: etapa preictal, etapa ictal, etapa postictal y la etapa interictal [2]. Según [3] el reto principal en el pronóstico de las crisis epilépticas consiste en diferenciar entre los estados preictal e interictal.

La detección y la predicción de crisis epilépticas son tareas que han exigido la intervención de la tecnología. Actualmente, una de las herramientas más avanzadas en la tarea de clasificación y reconocimiento de patrones son las máquinas con vectores de soporte (SVM). Uno de los primeros estudios que relacionan la detección de epilepsia con las SVM fue presentado por Nurettin Acir y Cüneyt Güzelış en el 2003 [4] pueden mencionarse tesis similares como [2] o bien [5].

Las herramientas de inteligencia computacional, como lo son las redes neuronales artificiales, también juegan un papel importante en la detección más efectiva de la epilepsia. Entre los estudios dedicados a su implementación el artículo: "Artificial Neural Network based epileptic detection using time-domain and frequency-domain features" [6], es uno de los estudios con mejores resultados, alcanzando una exactitud del 99.6 % con una sola característica de entrada. Adicionalmente se encuentran estudios similares en [7] y [8].

## Justificación

La epilepsia es una de las principales enfermedades neurológicas crónicas y no transmisibles. Es una alteración de la función de las neuronas de la corteza cerebral que se manifiesta como un proceso discontinuo de eventos clínicos denominados crisis epilépticas. La prevalencia de epilepsia en países no desarrollados oscila entre 10-20 por cada 100,000 habitantes. En Guatemala se estima una prevalencia de 1882 pacientes con epilepsia en la población general, una tasa de 5.8 por 1000 habitantes [9]. Se estima que el 70 % de las personas con epilepsia podrían vivir sin convulsiones si se diagnosticaran y trataran adecuadamente [1].

En la mayoría de los casos, el proceso de diagnóstico de esta patología requiere el análisis de un médico experto que interprete exhaustivamente los exámenes de exploración neurológica, específicamente el electroencefalograma, para detectar la presencia de crisis epilépticas e indicios que predicen la existencia de estas. Sin embargo, es una tarea compleja debido a la naturaleza, longitud y singularidades de los diversos tipos de crisis epiléptica que existen.

El principal tratamiento para la epilepsia es el farmacológico: las crisis epilépticas pueden controlarse con medicación en un 70 % de los casos [2]. Sin embargo, la detección del tipo de crisis epiléptica es crucial para la elección de fármacos debido a que el uso de los mismos implica efectos secundarios importantes en la vida de los pacientes. Cuando los fármacos no logran controlar las crisis epilépticas existen tratamientos alternativos como la estimulación del nervio vago o la cirugía. Sin embargo, al ser invasivas implican mayor riesgo y restricciones en la vida de los pacientes.

La intervención de la ingeniería y la tecnología ha permitido mediante herramientas computacionales la detección de patrones, clasificación y procesamiento de señales biomédicas. Gracias a esto, es posible caracterizar y analizar la información contenida en las señales EEG con el fin de automatizar y facilitar la detección y caracterización de crisis epilépticas en los mismos. Además, puede hacer posible la predicción de dichas crisis, lo cual sería una herramienta de gran utilidad para determinar el tratamiento adecuado en cada paciente.

# Objetivos

## Objetivo General

Desarrollar y aplicar técnicas y algoritmos de aprendizaje de máquina a señales biomédicas de pacientes con epilepsia, con el fin de encontrar características y patrones relevantes de dicha enfermedad.

## Objetivos Específicos

- Conocer y comprender características de las señales biomédicas en pacientes con epilepsia.
- Analizar técnicas existentes para el reconocimiento de patrones en señales biomédicas y seleccionar aquella(s) que faciliten la extracción de características relevantes para la identificación de episodios epilépticos.
- Aplicar las técnicas seleccionadas a señales biomédicas de pacientes con y sin epilepsia, y validar los resultados mediante asesoría médica y comparación con estudios similares.
- Diseñar e implementar una herramienta de software que permita procesar fácilmente las señales y aplicarles las técnicas de reconocimiento de patrones desarrolladas.

## Marco teórico

### Epilepsia

#### Causas

La epilepsia se define como un trastorno neuronal crónico, que consiste en episodios de descargas eléctricas bruscas, espontáneas, recurrentes, incontrolables y sostenidas en el cerebro; llamados convulsiones, o crisis epilépticas. Las causas de la epilepsia pueden clasificarse en dos grandes categorías: Hereditarias/congénitas y adquiridas. Las causas hereditarias y congénitas consisten en factores genéticos de predisposición a padecer crisis convulsivas y a errores congénitos del desarrollo. Entre estas, pueden mencionarse: anomalías cromosómicas, lesiones intraútero, displasias cerebrales, trastornos congénitos del metabolismo, malformaciones vasculares y tumores cerebrales.

Por otra parte, las causas adquiridas son posibles causas independientes a la herencia y factores congénitos. Entre estas, se pueden mencionar: traumatismo, lesiones postquirúrgicas, infartos y hemorragias cerebrales, tumores, Alcohol y otras drogas, enfermedades degenerativas (demencias y otras) y enfermedades metabólicas adquiridas. [2].

## Diagnóstico

El diagnóstico de la epilepsia es esencialmente clínico, es decir, las pruebas complementarias son de ayuda para la confirmación de la sospecha clínica o identifican causas responsables al cuadro clínico presentado por el paciente. Para el correcto diagnóstico de epilepsia, el paciente debe presentar una historia clínica de episodios de crisis epilépticas, se debe localizar la actividad eléctricamente aumentada, identificar el tipo de crisis y en base a esto definir el tipo de epilepsia.[10] Las herramientas diagnósticas pueden ser de tipo invasivas y no invasivas. A continuación, se presenta la herramienta principal utilizada para la valoración del diagnóstico.[2].

## Electroencefalograma: EEG

El electroencefalograma (EEG) es el registro de la actividad eléctrica de las neuronas del encéfalo. Dicho registro posee formas complejas que varían mucho con la localización de los electrodos y entre los individuos. Esto se debe al gran número de interconexiones que presentan las neuronas y debido a la forma no uniforme del encéfalo. En 1929, Hans Berger registró la actividad eléctrica del encéfalo humano empleando un galvanómetro de cuerda [11]. las ondas en el EEG se clasifican de acuerdo a su frecuencia en cuatro bandas: Delta, Theta, Alfa y Beta; su amplitud y morfología expresada en forma de onda aguda, punta, complejos-punta-onda lenta y onda lenta.

En pacientes con sospecha de epilepsia, el monitoreo prolongado del electroencefalograma (V-EEG), permite la identificación de la actividad ictal (durante las crisis) e interictal (fuera de las crisis); permite la correcta clasificación de las convulsiones y la correlación del comportamiento del paciente con los hallazgos electroencefalográficos. Durante los estudios de V-EEG se utilizan electrodos de superficie no invasivos, pero se pueden incluir también electrodos semi invasivos, tales como los esfenoidales (alambre de plata recubierto de teflón), colocados mediante anestesia local en la fosa zigomática y que permiten un registro más cercano a los polos de los lóbulos temporales. Mediante estos electrodos es posible registrar la actividad anormal en estados interictales, la cual ofrece información acerca de la ubicación de la zona irritativa (donde ocurre la crisis) .

El registro ictal se caracteriza por la presencia de actividad rítmica y sinusoidal en el rango de la actividad theta (4 a 7 Hz), beta (mayor a 13 Hz), alfa (8 a 10 Hz) o por descargas repetitivas, las cuales evolucionan en frecuencia, campo o amplitud. También es posible observar una atenuación o supresión de la actividad en crisis que se originan en regiones extra temporales, particularmente en los lóbulos frontales. [12]

## Caracterización de Señales EEG

Una característica es un parámetro que describe un comportamiento y facilita el análisis de una señal. En una señal electroencefalográfica, estas características pueden ordenarse en 5 grupos. [13]

- Características en el dominio del tiempo
- Características en el dominio de la frecuencia
- Coeficientes auto-regresivos
- Características wavelet
- Características cepstrales

En señales EEG las características más comunes son las siguientes: amplitud de ondas, duración de onda, medidas de histograma, desviación estándar, simetría de onda, cruces por cero, picos de autocorrelación, transformada de Fourier, media aritmética, curtosis y asimetría. A lo largo de esta investigación se detalla brevemente algunas de ellas.

Existen diversas técnicas para caracterizar una señal, una de las principales es mediante los momentos centrales de la señal. El momento central o centrado de orden  $n$  de una variable aleatoria  $x$ , se define mediante una ecuación que relaciona el operador de esperanza matemática, el valor esperado (media) y la función de densidad de probabilidad (FDP) de la variable a analizar. El primer momento central de una señal es cero, el segundo es la varianza (desviación estándar al cuadrado), el tercer momento se denomina “Skewness” o “asimetría estadística” y el cuarto se denomina “Kurtosis”. [2]

El segundo momento central (la varianza), es una de las características más sencillas de analizar una señal EEG y uno atributo utilizado para la caracterización de estas señales. Sin embargo, la FDP de  $x$  es normalmente desconocida. En consecuencia, se asume un comportamiento promedio a largo plazo de la señal dinámica y se sustituye la esperanza matemática por un promedio muestreado en el dominio del tiempo. El cuarto momento central (Kurtosis) analiza el grado de concentración de muestras entorno a la media, valores altos de Kurtosis indican que gran parte de la varianza es debido a infrecuentes desviaciones extremas. Este momento central es también un atributo utilizado para la caracterización de señales EEG ya que la FDP de las muestras durante las crisis tienden a tener una mayor concentración en torno a su media.[2]

Adicional a los momentos centrales de los registros EEG, existen técnicas complejas para la caracterización y detección de crisis epilépticas. características tales como la existencia de ciclos límites (actividad alpha, actividad ictal), fenómenos de salto (histéresis), comportamiento en frecuencia dependiente de la amplitud (cuanto más pequeña es la amplitud, mayor es la frecuencia del EEG) o la existencia de armónicos de frecuencia, son típicas de sistemas no lineales [14]. El uso de análisis no lineales aplicados a registros intracraneales es capaz de detectar incluso la etapa de transición preictal y hace posible reconstruir el sistema en el llamado espacio fase o espacio de estados, que permite obtener información clave acerca

de su comportamiento dinámico y la predicción no lineal a diferencia de los métodos lineales mencionados anteriormente.

Entre estas técnicas se pueden mencionar la Densidad de Correlación, el cual es el indicador de actividad epiléptica más utilizado y se define como la probabilidad de que dos vectores, seleccionados de manera aleatoria extraídos de la serie temporal concatenando  $N$  muestras consecutivas, estén separados por una distancia  $r$  el uno del otro. En relación al EEG al representar en el dominio temporal este valor, se produce un descenso de varios ordenes de magnitud antes del comienzo de la etapa ictal.[15]

Otra técnica a mencionar es la Probabilidad Conjunta, la cual evalúa cuan probable es la presencia de los datos de un segmento dentro de un conjunto dado de ellos [16]. La función de densidad en la etapa ictal es destacada por ser más estrecha que la etapa interictal(cuando no hay crisis). Debido a esta disparidad es posible utilizar la probabilidad conjunta para la detección de artefactos de la señal (normalmente eventos transitorios e inesperados), en este caso la crisis epiléptica.

## **Clasificación y Reconocimiento de Patrones de Señales EEG en Pacientes con Epilepsia**

La calidad de vida de estos pacientes se ve extremadamente afectada por la ocurrencia de las crisis epilépticas en apariencia impredecible. Por tanto, es importante el desarrollo de métodos de predicción de convulsiones epilépticas que pudieran mejorar la calidad de vida de estos pacientes permitiendo anticiparse a estos eventos para tomar acciones que podrían evitar el inicio de la crisis epiléptica y minimizar su impacto. [17]

El sistema generalizado de reconocimiento de patrones es un proceso lógico y ordenado de etapas mediante el cual puede darse un proceso de clasificación exitoso. Puede sintetizarse en 4 fases:

- **Preprocesamiento de la Señal:** Preparación de las señales para facilitar su análisis. Las señales EEG, presentan características propias debido a su naturaleza, como lo es el ruido por movimiento muscular. Las técnicas más utilizados para procesar EEG son: Filtros digitales, Análisis espectral autorregresivo, Periodograma, DWT y Transformada de Fourier.
- **Extracción de Características:** Las características más comunes de señales EEG y su clasificación se mencionan previamente en la sección caracterización de señales EEG.
- **Selección de Características Relevantes:** El objetivo principal de esta etapa es evitar la redundancia de datos y asegurar que sean relevantes para pertenecer a una muestra que represente la finalidad del estudio. La herramienta más utilizada en señales EEG para esta tarea es el análisis de componentes principales, PCA.

- **Diseño e Implementación del Clasificador:** Es el proceso de encontrar en un espacio de características una función que separe las distintas clases que la componen. Para fines de este estudio se analizarán algunos tipos de Redes Neuronales Artificiales (ANN) y las máquinas con vectores de soporte (SVM). El objetivo de un clasificador es escoger el hiperplano óptimo de separabilidad.

## Máquinas de Vectores de Soporte

La máquina de vectores de soporte (SVM) se basa en la construcción de un hiperplano, o un conjunto de hiperplanos, en un espacio de dimensionalidad muy alta o incluso infinita, como superficie de decisión, de tal manera que permita clasificar un conjunto de muestras separando unas de otras. Este tipo de algoritmos buscan el hiperplano que tenga la máxima distancia (margen) con los puntos que estén más cerca del mismo.

La manera más simple de realizar la separación es mediante una línea recta, un plano o un hiperplano N-dimensional directamente en el espacio de los datos de entrada, esto es lo que se conoce como SVM lineal. Desafortunadamente, debido a las limitaciones de las máquinas de aprendizaje lineal, éstas no proporcionan un rendimiento óptimo en muchas aplicaciones del mundo real. La representación por medio de funciones núcleo (“kernel”) ofrece una solución a este problema, proyectando la información a un espacio de características de mayor dimensión el cual aumenta la capacidad computacional de las máquinas de aprendizaje lineal [2].

Además del kernel, a la hora de entrenar una SVM es también necesario elegir el valor de la penalización del error que se desea tener (a partir de ahora C). De C dependerá la distancia de los márgenes al hiperplano, un valor de C más alto hace que los márgenes se reduzcan, mejorando la clasificación de las muestras [18].

## Redes Neuronales

La neurona artificial se caracteriza por tener unas entradas  $X_i$ , una o varias salidas  $Y_j$  y un peso de tendencia  $b_j$ , donde cada entrada tiene asociado un peso  $W_{ij}$  relacionándola con las siguientes neuronas. Es posible calcular la entrada neta de cada neurona perteneciente a la red, sumando la multiplicación de sus entradas con sus respectivos pesos asociados y adicionando el peso de tendencia mediante la siguiente ecuación:

$$N_j = \sum_i X_i * W_{ij} + b_j \quad (1)$$

Donde N es la entrada neta, la cual permite encontrar la salida neta de la red evaluando en una función de activación  $y = Fact(N)$ . Esta función de activación puede ser de diferentes tipos dependiendo de la naturaleza de las señales a analizar. El aprendizaje de todas las redes está asociado con la modificación de los pesos sinápticos mediante un proceso iterativo. Computacionalmente la red cumple con las etapas de pre-procesamiento (Normalización), Procesado (Regularización, validación y prueba) y post-procesamiento (des-normalizar).



## Metodología

La enfermedad de la epilepsia, se considera como una enfermedad dinámica por lo que no es un proceso sencillo detectar las crisis epilépticas o predecir cuando ocurrirán las mismas inspeccionando directamente el electroencefalograma. Por esto, es necesario implementar técnicas de caracterización para optimizar su análisis. Para la implementación de la metodología se seguirán 4 fases previamente mencionadas en la sección de clasificación de patrones de señales EEG en pacientes con epilepsia.

### Preprocesamiento de la Señal

Las señales EEG presentan características intrínsecas debido a su naturaleza. Por esto en este proyecto se considera necesario utilizar técnicas de filtrados digitales de tipo Butterworth para eliminar ruidos y artefactos que no interesan en el análisis a realizar. Se propone implementar un filtro notch de 2º orden de 60Hz para eliminar la interferencia eléctrica y posteriormente un filtro pasabanda de 2º orden de 0.5-70Hz para eliminar ruidos de alta y baja frecuencia que no se encuentren en el espectro de frecuencia de la señal de interés.

Para la preparación previa de la señal a analizar se decide implementar la técnica de enventanado la cual consiste dividir la señal en segmentos de cierta cantidad de muestras  $[n]$  para optimizar el proceso de análisis y disminuir la carga computacional tomándose en cuenta que el estudio V-EEG puede durar varias horas. Los resultados del análisis dependerán directamente del tamaño de las ventanas a utilizar. En este proyecto se realizarán experimentos utilizando diversos tamaños de ventana para definir finalmente cuales presenten mejores resultados.

### Extracción de Características

Como se mencionó en secciones anteriores las características en un electroencefalograma se pueden clasificar en 5 grupos. Para fines de este proyecto se utilizarán características en el dominio del tiempo y frecuencia. Existen diversas técnicas de caracterización que permiten estudiar las características por lo que es necesario analizar cuales técnicas mejorarán los resultados y facilitarán el análisis. Por esto se propone implementar la caracterización mediante momentos centrales de la señal, en específico la varianza y la curtosis. Adicionalmente se pretende utilizar la técnica de probabilidad conjunta tomándose en cuenta que esta técnica ha generado buenos resultados en proyectos similares para clasificar el período ictal e interictal de la crisis epiléptica, así como la obtención de características mediante la transformada de wavelet.

Cabe mencionar que estas dos últimas técnicas propuestas son de mayor complejidad que calcular los momentos centrales de la señal. Sin embargo, debido a su no linealidad permiten obtener información acerca del comportamiento dinámico de la enfermedad. Con la técnica de probabilidad conjunta puede evaluarse cuán probable es la presencia de los datos de un segmento dentro de un conjunto dado de ellos, permitiendo detectar la presencia de artefactos. En este caso el artefacto será la presencia de crisis (etapa ictal) del EEG.

## Selección de Características

Posterior a implementar las técnicas de caracterización a las ventanas de la señal es necesario seleccionar que características son relevantes, para esto se propone realizar experimentos con canales que describen etapas ictales y estudiar su comportamiento para comparar que diferencias presenta en relación a las demás etapas. En base a estos resultados se seleccionaran las características que mejor describan las señales y faciliten su clasificación para finalmente obtener un vector de características que nos servirá para implementar conceptos de máquinas de aprendizaje para detectar las crisis epilépticas y la posible predicción de las mismas.

## Diseño e Implementación del Clasificador

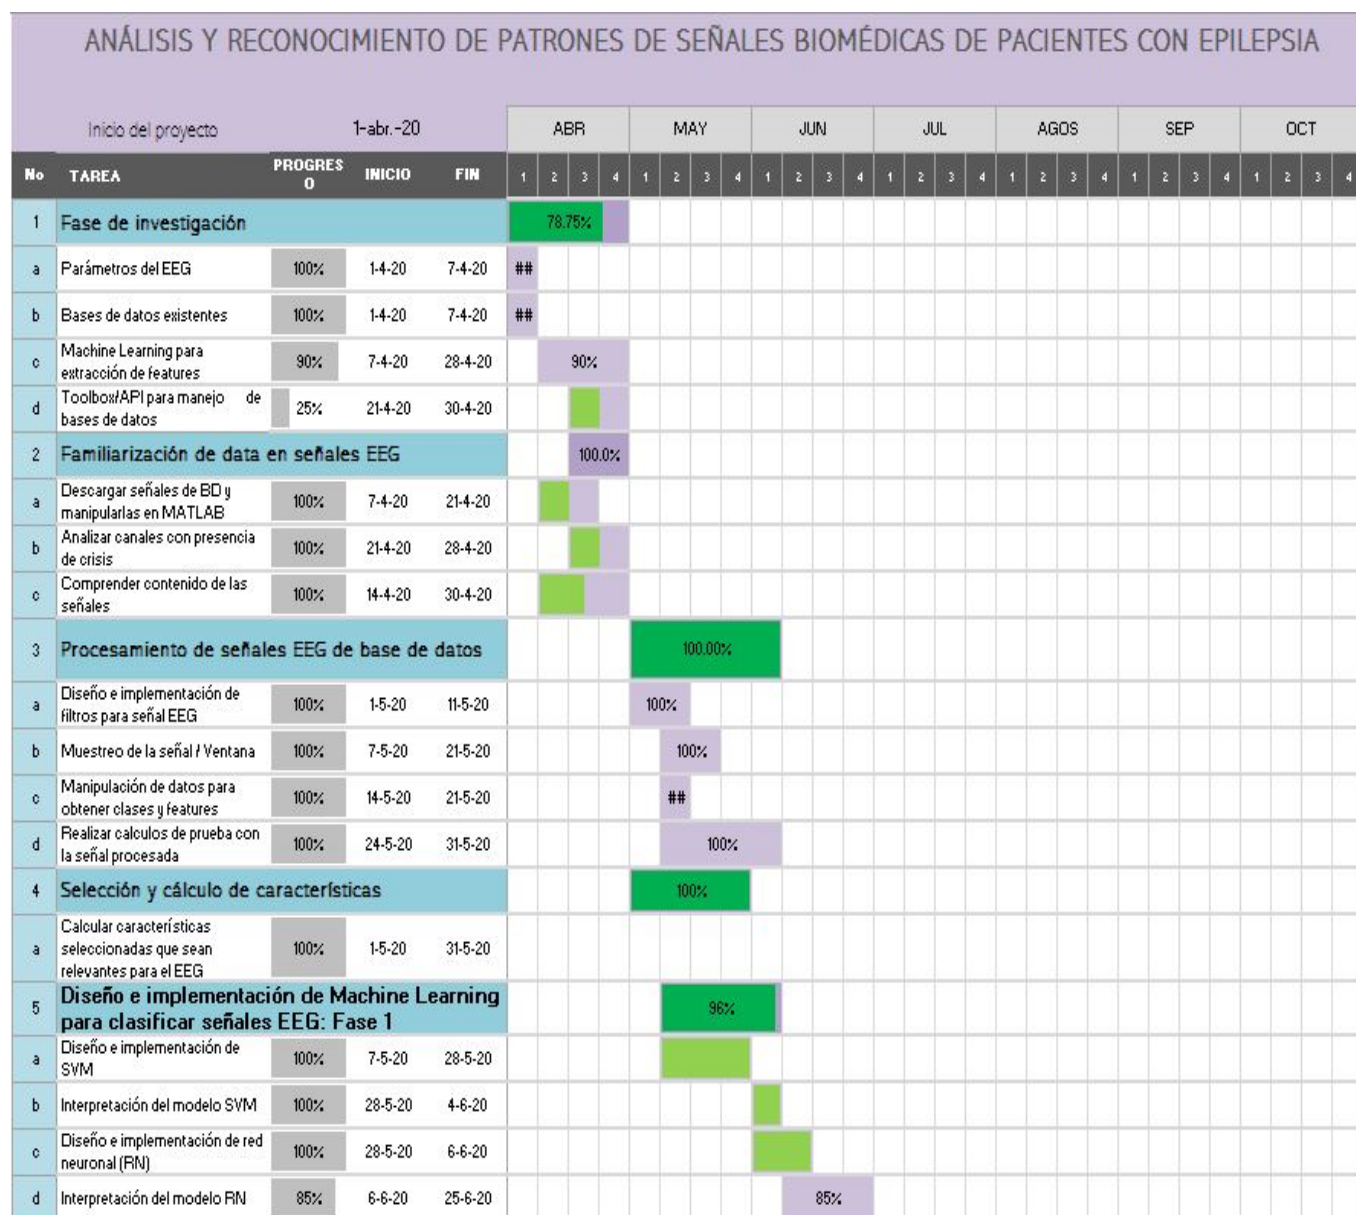
El diseño e implementación del clasificador será la fase principal del proyecto ya que en dependencia a la exactitud y a la veracidad del mismo será la calidad de los resultados. En este proyecto se pretende utilizar máquinas con vectores de soporte y redes neuronales como clasificadores de la señal y finalmente realizar comparaciones de resultados con estudios similares y asistencia médica.

Como primera etapa se diseñará e implementará las máquinas de vectores de soporte mediante la librería *libSVM* disponible gratuitamente para diversas plataformas de programación. Para fines de este proyecto, se decidió utilizar la herramienta MATLAB debido a su versatilidad para realizar simulaciones y presentar resultados. El diseño de este clasificador será de carácter experimental por lo que se realizarán el mayor número de experimentos posibles para elegir que parámetros permiten construir el hiperplano óptimo para la clasificación, debido a la complejidad de las señales se descarta utilizar la separación lineal.

Como segunda etapa se pretende diseñar e implementar una red neuronal artificial utilizando las herramientas *Neural Network Toolbox*, *Wavelet Toolbox* y *Signal Processing Toolbox* para crear, entrenar y visualizar gráficamente las redes neuronales. Para ambas etapas se evaluarán los rendimientos de los clasificadores utilizando validación cruzada, se obtendrán matrices de confusión, y se calcularán estadísticas de porcentajes de clasificación correcta.

Como se mencionó previamente los resultados de este proyecto servirán para alimentar una base datos de señales biomédicas con el fin de contribuir a la comunidad científica que desee continuar analizando este tipo de señales. Para facilitar la manipulación de los datos y la presentación de los resultados a los usuarios que utilizarán posteriormente la base de datos se diseñara un entorno de desarrollo (Toolbox) con la plataforma MATLAB que permita acceder a las señales fácilmente, incluir funciones de programación útiles para la aplicación y genere gráficas para mostrar resultados y comportamiento de las señales.

## Cronograma de actividades



# ANÁLISIS Y RECONOCIMIENTO DE PATRONES DE SEÑALES BIOMÉDICAS DE PACIENTES CON EPILEPSIA

Inicio del proyecto					1-abr.-20				ABR				MAY				JUN				JUL				AGOS				SEP				OCT			
No	TAREA	PROGRESO	INICIO	FIN	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4				
6	Diseño e implementación de Machine Learning para clasificar señales EEG: Fase 2																																			
a	Ajustes de parámetros SVM	0%	25-6-20	16-7-20																																
b	Elección tamaño de ventana	40%	2-7-20	16-7-20																																
c	Elección partición validación cruzada	40%	2-7-20	16-7-20																																
d	Ajustes parámetros RN	0%	25-6-20	16-7-20																																
e	Elección función de entrenamiento	40%	2-7-20	9-7-20																																
f	Elección número de capas invisibles	50%	2-7-20	9-7-20																																
g	Realizar pruebas con Base de datos HUMANA o Physionet	0%	16-7-20	3-8-20																																
7	Emplear técnicas de caracterización complejas																																			
	Encontrar función de densidad de probabilidad	0%	20-7-20	27-7-20																																
	Calcular probabilidad conjunta	0%	27-7-20	31-7-20																																
	Emplear transformada de wavelet	0%	3-8-20	3-9-20																																
	Analizar espectro de frecuencia de señales	0%	27-7-20	7-8-20																																
8	Validación del clasificador implementado																																			
a	Comparar resultados con interpretaciones médicas	0%	7-9-20	21-9-20																																
b	Comparar resultados de trabajos	0%	7-9-20	15-9-20																																
9	Diseño de Toolbox /API para manejo de BD		fecha	fecha																																
a	Realizar funciones para facilitar manejo de BD	0%	7-9-20	21-9-20																																
b	Organizar forma de presentar resultados	0%	21-9-20	7-10-20																																
10	Redacción de tesis																																			
11	Presentación de tesis																																			

Prefacio . . . . .	14
Lista de Figuras . . . . .	14
Lista de Cuadros . . . . .	14
Resumen . . . . .	14
Abstract . . . . .	14
<b>1.Introducción</b>	<b>14</b>
<b>2.Antecedentes</b>	<b>14</b>
<b>3.Justificación</b>	<b>14</b>
<b>4.Objetivos</b>	<b>14</b>
<b>5.Marco Teórico</b>	<b>14</b>
5.1 Epilepsia . . . . .	14
5.1.1 Definición y Características . . . . .	14
5.1.2 Relevancia . . . . .	14
5.1.3 Diagnóstico . . . . .	14
5.1.4 Clasificación de Crisis Epilépticas . . . . .	14

5.2 Electroencefalograma: EEG . . . . .	14
5.2.1 Definición . . . . .	14
5.2.3 Tipos de Montaje . . . . .	14
5.2.4 Clasificación de Ondas . . . . .	14
5.2.5 Artefactos . . . . .	14
5.2.6 Uso del EEG en la Epilepsia . . . . .	14
5.2.7 Características de Crisis Epilépticas en el EEG . . . . .	14
5.3 Procesamiento de Señales . . . . .	14
5.3.1 Filtrado de Señales . . . . .	14
5.3.2 Normalización de Señales . . . . .	14
5.3.3 Técnica de Enventanado de Señales . . . . .	14
5.3.4 Extracción de Características . . . . .	14
5.3.5 Técnicas de Caracterización . . . . .	14
5.3.6 Selección de Características . . . . .	14
5.4 Aprendizaje de Máquina para Detección de Crisis Epilépticas . . . . .	14
5.4.1 Diseño de Clasificadores . . . . .	14
5.4.2 Tipología de Clasificadores . . . . .	14
5.4.3 Máquina de Vectores de Soporte, SVM . . . . .	14
5.4.4 Redes Neuronales, ANN . . . . .	14
5.5 Rendimiento de Clasificadores . . . . .	14
5.5.1 Exactitud, (accuracy) . . . . .	14
5.5.2 Validación Cruzada . . . . .	14
5.5.3 Matrices de Confusión . . . . .	14

## **6. Resultados 14**

6.1 Desiciones de Diseño de Clasificadores . . . . .	14
6.1.1 Máquinas de Vectores de Soporte . . . . .	14
6.1.2 Redes Neuronales . . . . .	14
6.2 Entrenamiento y Simulación de Clasificadores . . . . .	14

6.2.1 Máquinas de Vectores de Soporte . . . . .	14
6.2.2 Redes Neuronales . . . . .	14
6.3 Resultados de los Clasificadores . . . . .	14
6.3.1 Características en el Dominio del Tiempo . . . . .	14
6.3.2 Características en el Dominio de Frecuencia . . . . .	14
6.3.3 Empleando Transformada Wavelet . . . . .	14
6.4 Comparación de Rendimiento de Clasificadores . . . . .	14
6.4.1 Resultados de Investigaciones Relacionadas . . . . .	14

## Referencias

- [1] (Jun. de 2019). Notas Descriptivas: Epilepsia, dirección: <https://www.who.int/es/news-room/fact-sheets/detail/epilepsy>.
- [2] A. Boris Valiente, “Detección de crisis epilépticas en el dominio temporal a partir del EEG mediante SVMs”, Tesis de mtría., 2014.
- [3] K. Gadhomi, J.-M. Lina, F. Mormann y J. Gotman, “Seizure prediction for therapeutic devices: A review”, *Journal of neuroscience methods*, vol. 260, págs. 270-282, 2016.
- [4] N. Acir y C. Güzelis, “Automatic spike detection in EEG by a two-stage procedure based on support vector machines”, *Computers in Biology and Medicine*, vol. 34, n.º 7, págs. 561-575, 2004.
- [5] N. Angulo, J. Sanz, V. Malavé, M. Barrera, H. Spinetti y P. Guillén, “Máquinas de aprendizaje para clasificar señales electroencefalográficas”, *Avances en Sistemas e Informática*, vol. 6, n.º 1, págs. 213-218, 2009.
- [6] V. Srinivasan, C. Eswaran, Sriraam y N, “Artificial neural network based epileptic detection using time-domain and frequency-domain features”, *Journal of Medical Systems*, vol. 29, n.º 6, págs. 647-660, 2005.
- [7] A. Ceballos Herrera y col., “Detección de epilepsia en señales de electroencefalografía, mediante el uso de redes neuronales artificiales y máquinas con vectores de soporte”, B.S. thesis, Universidad Autónoma de Occidente, 2010.
- [8] M. K. Kiymik, A. Subasi y H. R. Ozcalik, “Neural networks with periodogram and autoregressive spectral analysis methods in detection of epileptic seizure”, *Journal of Medical Systems*, vol. 28, n.º 6, págs. 511-522, 2004.
- [9] J. F. Vásquez López, “Calidad de vida en pacientes con epilepsia”, Tesis doct., Universidad de San Carlos de Guatemala, 2015.
- [10] J. A. French, “Refractory epilepsy: clinical overview”, *Epilepsia*, vol. 48, págs. 3-7, 2007.
- [11] F. Ramos-Argüelles, G. Morales, S. Egozcue, R. Pabón y M. Alonso, “Técnicas básicas de electroencefalografía: principios y aplicaciones clínicas”, en *Anales del sistema sanitario de Navarra*, SciELO Espana, vol. 32, 2009, págs. 69-82.

- [12] P. Shkurovich Bialik y M. Collado Corona, “Avances en el manejo de la epilepsia”, *Departamento de Neurofisiología Clínica. Centro Neurológico. Centro Médico ABC*, vol. 45, n.º 1, págs. 26-31, 2017.
- [13] A. Aarabi, F. Wallois y R. Grebe, “Automated neonatal seizure detection: a multistage classification system through feature selection based on relevance and redundancy analysis”, *Clinical Neurophysiology*, vol. 117, n.º 2, págs. 328-340, 2006.
- [14] C. Elger, G. Widman, R. Andrzejak, J. Arnhold, P. David y K. Lehnertz, “Nonlinear EEG analysis and its potential role in epileptology”, *Epilepsia*, vol. 41, S34-S38, 2000.
- [15] J. Martinerie, C. Adam, M. Le Van Quyen, M. Baulac, S. Clemenceau, B. Renault y F. J. Varela, “Epileptic seizures can be anticipated by non-linear analysis”, *Nature medicine*, vol. 4, n.º 10, págs. 1173-1176, 1998.
- [16] A. Delorme, S. Makeig y T. Sejnowski, “Automatic artifact rejection for EEG data using high-order statistics and independent component analysis”, en *Proceedings of the third international ICA conference*, 2001, págs. 9-12.
- [17] S. A. Villazana León, A. A. Eblen Zajjur, G. R. Montilla León y C. O. Seijas Fossi, “Detección de cambios abruptos en señales epilépticas del EEG”, *Archivos de Neurociencias*, vol. 22, n.º 3, págs. 6-18, 2018.
- [18] B. Florentino Liaño, “Modelling and epileptic brain pattern classification”, Tesis de maestría., 2008.